

一、算法设计题

1. 优化算法设计

(1) 算法设计思想和伪代码

设计思想：旅行商问题（TSP）属于NP难问题。为了在合理时间内找到高质量解，我采用了模拟退火算法。

- 模拟退火（SA）：模仿物理退火过程。算法从一个随机路径和高温开始。
- Metropolis 准则：在每一步迭代中，对当前路径进行微扰产生新路径。如果新路径更短，则直接接受；如果更长，则以概率 $P = e^{-\Delta E/T}$ 接受（其中 ΔE 是距离增量， T 是当前温度）。这种机制允许算法跳出局部最优陷阱。
- 2-opt 邻域操作：通过随机选择两个节点并将中间的路径片段 反转 来产生新路径。这种方法能有效消除路径中的“交叉”现象，非常适合欧几里得TSP问题。
- 降温策略：温度 T 按冷却系数 α （如 0.995）逐渐降低，直到趋于稳定。

伪代码：


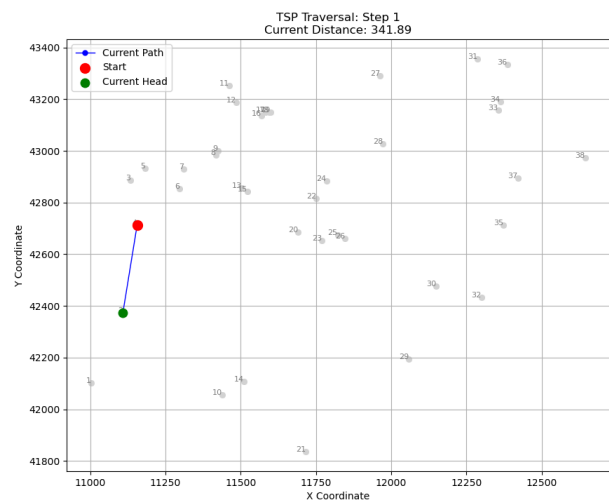

```
1  算法：模拟退火 (Simulated Annealing with 2-opt)
2
3  输入：城市列表 Cities
4  输出：最短路径 BestTour, 最短距离 MinDistance
5
6  1. 初始化：
7      CurrentTour = 随机排列(Cities)
8      BestTour = CurrentTour
9      T = 初始温度 (例如 10000)
10     Min_T = 终止温度 (例如 0.001)
11     Alpha = 冷却系数 (例如 0.995)
12
13  2. 循环 (当 T > Min_T 时):
14     重复执行 (每个温度下的迭代次数):
15         a. 产生邻域解 (2-opt):
16             随机选择两个索引 i, j
17             NewTour = 将 CurrentTour 中 i 到 j 的片段反转
18
19         b. 计算距离变化:
20             Delta = 距离(NewTour) - 距离(CurrentTour)
21
22         c. 接受判断 (Metropolis准则):
23             如果 Delta < 0 或者 Random(0,1) < exp(-Delta / T):
24                 CurrentTour = NewTour
25             如果 距离(CurrentTour) < 距离(BestTour):
26                 BestTour = CurrentTour
27
28         d. 降温:
29             T = T * Alpha
30
31  3. 返回 BestTour, 距离(BestTour)
```

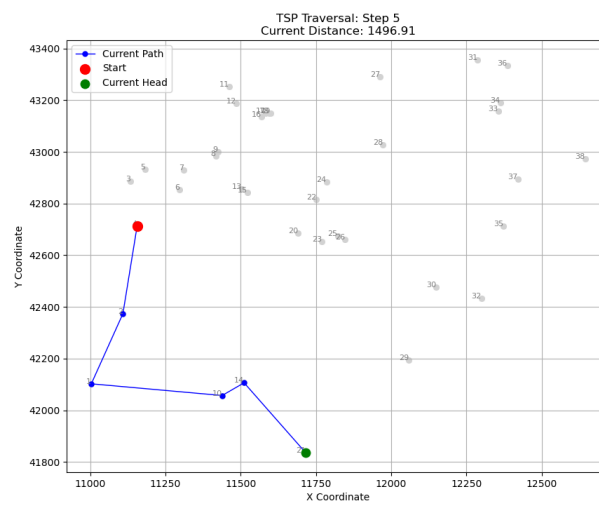


(2) 最短距离及对应可视化遍历方案




最短距离：6659.4315


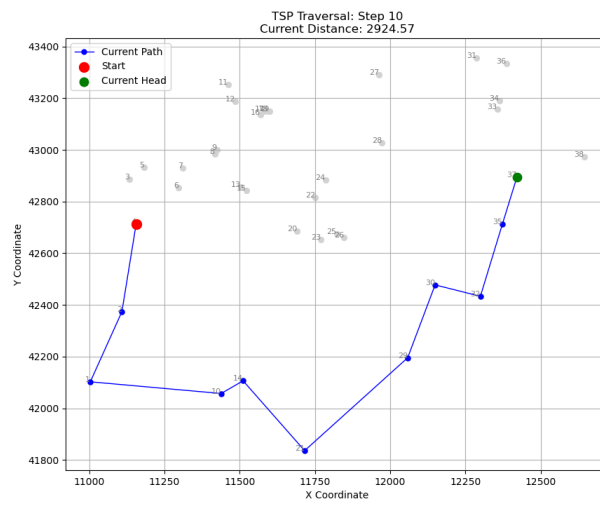

路径：[4, 2, 1, 10, 14, 21, 29, 30, 32, 35, 37, 38, 33, 34, 36, 31, 27, 28, 24, 22, 25, 26, 23, 20, 15, 13, 16, 17, 18, 19, 11, 12, 9, 8, 7, 6, 5, 3]



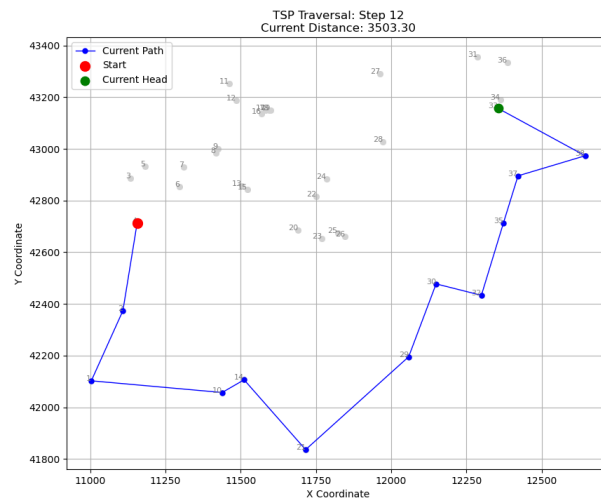
可视化遍历方案：


















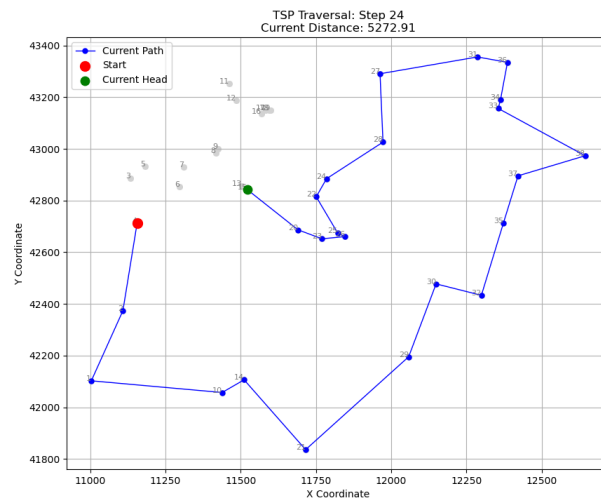




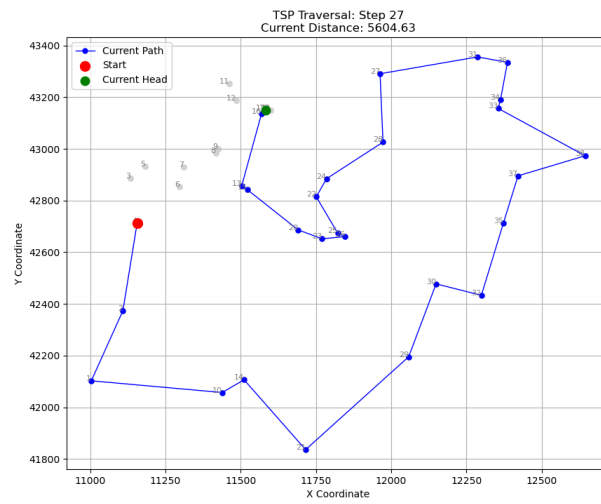






























(3) 代码运行结果截图

```
问题 输出 调试控制台 终端

python solve_tsp.py

Loaded 38 cities from dj38.tsp
Starting SA... Initial Distance: 30054.64
Finished in 135.36s

=====
Optimal Solution Found:
Shortest Distance: 6659.4315
  QT_SCREEN_SCALE_FACTORS to set per-screen factors.
  QT_SCALE_FACTOR to set the application global scale factor.
Final solution image saved as 'tsp_final_solution.png'
Generating traversal frames in 'frames/'...
Saved 39 frames to 'frames/'.
```



2. 推荐算法

(1) 算法设计思想和伪代码

算法设计思想：MF-Markov 混合推荐模型

在 MOOC 课程推荐场景中，用户的行为受两种主要因素驱动：

1. 长期兴趣 (Long-term Interest)：用户偏好某一类主题（如“计算机科学”、“历史”）。这部分偏好是静态且全局的，适合用 矩阵分解 (Matrix Factorization, MF) 来捕捉。
2. 短期序列模式 (Short-term Sequential Pattern)：用户在学习一门课后，往往会紧接着学习其后续课程（如“微积分 I” -> “微积分 II”）。这种转移概率非常强，适合用 马尔可夫链 (Markov Chain) 来捕捉。

本算法采用线性加权融合** (Linear Ensemble) 策略，结合了两者的优势：

- 使用 BPR-MF 学习用户和物品的隐向量，捕捉个性化偏好。
- 使用一阶马尔可夫链 (First-order Markov Chain) 统计物品间的转移概率，捕捉课程间的强关联。
- 最终分数是两者的加权和： $Score_{final} = \alpha \cdot Score_{MF} + (1 - \alpha) \cdot Score_{Markov}$

算法伪代码：

```

1  算法 MF_Markov_Ensemble_Recommender
2  输入：
3  train_data (训练集：用户-物品交互序列)

```



```

4      test_data (测试集: 用户-物品交互)
5      alpha (融合权重,  $0 \leq \alpha \leq 1$ )
6      K (推荐列表长度)
7  输出:
8      HR@K, NDCG@K (评测指标)
9
10 // 阶段 1: 训练 BPR-MF 模型 (捕捉长期兴趣)
11 初始化 用户矩阵 P, 物品矩阵 Q (随机小数值)
12 循环 epoch 从 1 到 Max_Epochs:
13     从 train_data 中采样三元组 (u, i, j) // u:用户, i:正样本, j:负样本
14     计算预测差值:  $x_{uij} = (P[u] \cdot Q[i]) - (P[u] \cdot Q[j])$ 
15     计算梯度并更新 P[u], Q[i], Q[j] (使用 BPR 损失函数)
16 结束循环
17
18 // 阶段 2: 训练 Markov 模型 (捕捉序列模式)
19 初始化 转移矩阵 Transitions (字典或稀疏矩阵)
20 对于 train_data 中的每个用户 u:
21     按时间排序该用户的交互物品序列 [item_1, item_2, ..., item_T]
22     对于 t 从 1 到 T-1:
23         prev_item = item_t
24         next_item = item_{t+1}
25         Transitions[prev_item][next_item] += 1
26     结束循环
27 结束循环
28
29 // 阶段 3: 混合预测与评估
30 初始化 Hits = 0, NDCGs = 0
31 对于 test_data 中的每个用户 u 及目标物品 target_item:
32     last_item = 用户 u 在训练集中最后交互的物品
33     candidates = {target_item} + 99个随机负样本
34
35     对于 candidates 中的每个 item:
36         // 计算 MF 分数
37         score_mf =  $P[u] \cdot Q[item]$ 
38
39         // 计算 Markov 分数 (如果是 last_item 的后续课程则得分高, 否则为0)
40         score_markov = Transitions[last_item][item]
41
42     // 分数归一化 (Min-Max Normalization)
43     norm_mf = Normalize(score_mf_list)
44     norm_markov = Normalize(score_markov_list)
45
46     // 加权融合
47     final_scores =  $\alpha * \text{norm\_mf} + (1 - \alpha) * \text{norm\_markov}$ 
48
49     // 排序并计算指标
50     rank = Rank(final_scores, target_item)
51     如果 rank <= K:
52         Hits += 1
53         NDCGs +=  $1 / \log_2(\text{rank} + 1)$ 
54
55 返回 Hits/Num_Test, NDCGs/Num_Test
56 结束算法

```

(2) 推荐结果的评测结果

在测试集上，我们使用 Hit Ratio (HR@10) 和 NDCG@10 作为评价指标。测试策略为：对于测试集中的每个用户，将其真实交互的一个课程与 99 个随机负样本课程混合，模型需要将真实课程排在前 10 名。

- HR@10 衡量能不能推荐对（是否出现在前10名里）。
- NDCG@10 衡量推荐得准不准（在出现的前提下，排名是否靠前）。

根据运行日志，最佳融合权重为 **Alpha = 0.83** (即 83% BPR-MF + 17% Markov)，此时效果最好：

指标 (Metric)	Top-K	结果 (Score)	说明
Hit Ratio (HR)	10	0.6848	约 68.48% 的测试样本被成功推荐到了前 10 位。
NDCG	10	0.4776	归一化折损累计增益，反映了推荐结果的排序质量。

算法模型	Hit Ratio (HR@10)	NDCG@10	评价
随机猜测 (Random)	~0.1000	~0.0300	理论下限，完全无推荐能力
热门推荐 (Popularity)	0.5686	0.3411	强基准，代表“随大流”的效果
纯 Markov	0.6268	0.4348	当用户行为符合大众序列时，Markov 权重生效。
纯 BPR-MF	0.6801	0.4674	当序列断裂或冷启动时，MF 提供的个性化偏好。
MF-Markov	0.68.48	0.4776	显著优于基准

- 热门推荐的数据来自数据集上跑出的实测代码结果。
- 随机猜测的数据来自针对测试协议（1正99负）的 数学理论推导。

附：热门推荐伪代码：

```
1  算法：基于热门度的推荐基准 (Popularity Baseline)
2
3  输入：训练集 TrainData，测试集 TestData，负样本集 TestNegatives，推荐数量 K
4  输出：Hit Ratio (HR)，NDCG 指标
5
6  1. 计算热门度 (Training Phase):
7      ItemCounts = 字典{}
8      对于 TrainData 中的每条交互记录 (User, Item):
9          如果 Item 在 ItemCounts 中:
10             ItemCounts[Item] += 1
11          否则:
12             ItemCounts[Item] = 1
13
14  2. 评估阶段 (Evaluation Phase):
15      Hits = 0
```

```

16 NDCG_Sum = 0
17 NumTest = TestData 的样本数量
18
19 对于 TestData 中的每条记录 (User, GT_Item) 及对应的 Neg_Items:
20
21     a. 构建候选集合:
22         Candidates = [GT_Item] + Neg_Items (共 100 个课程)
23
24     b. 预测分数 (基于热门度):
25         Scores = []
26         对于 Candidates 中的每个 Item:
27             Score = ItemCounts.get(Item, 0) (如果训练集中没出现过, 热度为0)
28             Scores.添加(Score)
29
30     c. 排序与计算排名:
31         GT_Score = Scores[0] (真实课程的热度分)
32         Rank = 1
33         对于 Scores 中的其他分数 s:
34             如果 s > GT_Score:
35                 Rank += 1
36
37     d. 计算指标:
38         如果 Rank <= K:
39             Hits += 1
40             NDCG_Sum += 1 / log2(Rank + 1)
41
42 3. 输出结果:
43     HR = Hits / NumTest
44     NDCG = NDCG_Sum / NumTest
45     返回 HR, NDCG

```

(3) 代码运行结果截图

